

Unanswerable Question Detection in Document Visual Question Answering

Giuseppe Luciano Scrimali

Giugno 2026

1 Introduzione

Questo lavoro costruisce un benchmark sintetico su DocVQA con tre corruzioni rule-based (entity, element, layout), valuta tre Vision LLM di piccola taglia su classificazione binaria (ANSWERABLE/UNANSWERABLE) e confronta strategie di mitigazione in-context in setting single-page e multi-pagina.

2 Metodologia

2.1 Dataset

Per questo lavoro è stata scelta la famiglia **DocVQA** [1, 2], in quanto fornisce nativamente un dataset single-page (SP-DocVQA) e la sua estensione multipagina (MP-DocVQA), consentendo di confrontare i due setting con la stessa pipeline di corruzione e valutazione.

Per entrambi i dataset sono stati concatenati gli split **train** e **val** in un unico pool da cui campionare il benchmark; lo split **test** è stato escluso perché privo delle etichette **answers**.

Struttura di un campione. Entrambi i dataset condividono **questionId**, **question** e **answers**. La differenza principale è che MP-DocVQA sostituisce il singolo campo **image** con una lista di pagine **page_ids** e un indice **answer_page_idx** che indica quale pagina contiene la risposta. Il modello riceve una finestra di W pagine centrata su quest'ultima: $W=1$ equivale al caso singola pagina, $W=2$ aggiunge una pagina di contesto adiacente.

2.2 Selezione dei modelli Vision LLM

Sono stati scelti tre Vision LLM instruction-following di taglia comparabile (2B–4B), escludendo i modelli extractive perché inadatti a seguire istruzioni testuali e a produrre un output binario.

Modello	Org.	Params
Qwen2-VL-2B-Instruct	Alibaba	2B
Gemma-3-4B-it	Google	4B
Phi-3.5-vision-instruct	Microsoft	4B

Table 1: Modelli selezionati per l'inferenza.

I tre modelli appartengono a famiglie e organizzazioni diverse, garantendo varietà architeturale nel confronto.

I tre modelli richiedono versioni incompatibili della libreria **transformers** (Phi3.5: $\approx 4.48.0$; Gemma-3: ≥ 4.50 ; Qwen2-VL: ≥ 4.52), pertanto ogni modello è stato eseguito in una sessione Colab separata, con i risultati salvati su Drive tra una sessione e l'altra.

2.3 Parte 1 : Costruzione del Benchmark

Il benchmark è costruito a partire da domande originalmente rispondibili, corrotte sinteticamente per renderle *unanswerable*. L'obiettivo è valutare se il modello riconosce l'assenza di informazione guardando il documento, non inferendola dal solo testo della domanda: la domanda corrotta resta grammaticalmente corretta e plausibile, ma l'informazione richiesta non è presente nel documento visivo. Uno schema della pipeline è in Figura 1.

Tipi di corruzione. Sono definiti tre tipi di corruzione, ciascuno mirato a una diversa capacità visiva del modello:

- **Entity:** un'entità nominale (data, nome, organizzazione) viene sostituita, via NER (`spacy en_core_web_sm`), con un valore dello stesso tipo ma estraneo al dominio del dataset, per minimizzare la probabilità che sia comunque presente nel documento per coincidenza; interrogativi, acronimi e cardinali generici sono esclusi tramite blacklist. Testa lettura e confronto testuale.
- **Element:** il riferimento a un elemento di pagina (es. *table* $\rightarrow$ *figure*) viene sostituito con uno di gruppo semanticamente distante, individuato via regex. Testa la comprensione della struttura visiva.
- **Layout:** un riferimento spaziale (es. *top-left* $\rightarrow$ *bottom-right*) viene sostituito col suo opposto via regex, solo se seguito da un nome strutturale (es. *table*), per escludere usi non spaziali ("*top priority*"). Testa la localizzazione di elementi nella pagina.

Campionamento. Le domande corrompibili vengono identificate analizzando l'intero pool e suddivise in tre insiemi per tipo. Si campionano circa 100 campioni corrotti con distribuzione uniforme: 34 entity, 33 element, 33 layout.




Figure 1: Pipeline di costruzione del benchmark (Parte 1).

In SP-DocVQA il campionamento è stratificato per `question_type` con quota uniforme per categoria; le categorie presenti sono: **Image/Photo**, **Yes/No**, **figure/diagram**, **form**, **free_text**, **handwritten**, **layout**, **others**, **table/list**.

A differenza di SP-DocVQA, MP-DocVQA non include il campo `question_types`: per questo dataset il campionamento risulta quindi casuale anziché stratificato per tipologia di domanda.

LLM-as-a-judge. Ogni domanda corrotta è valutata da Llama-3.3-70B via Groq su due criteri:

- *well_formed*: grammaticalmente corretta;
- *needs_document*: impossibile capire l'unanswerability senza guardare il documento.

Se una domanda non supera i criteri, si tenta una riscrittura automatica; se fallisce anche il secondo tentativo, il campione viene scartato (REJECT) e un campione clean equivalente viene rimosso per mantenere il bilanciamento 50/50. In entrambi i task si è verificato un solo REJECT: il benchmark finale conta quindi 198 campioni (99 corrotti, 99 clean), mescolati casualmente.

TITO: ENTITY
MODIFICA: Pennsylvania Dietetic Association (DRC) -> Marwick & Vale
ORIGINALE: Who is the President of Pennsylvania Dietetic Association?
CORROTTA: Who is the President of Marwick & Vale?




Figure 2: Esempio di corruzione del tipo ENTITY nel task DocVQA Multi Page.

2.4 Parte 2: Valutazione dei Modelli

Prompt e inferenza. La Figura 3 illustra la pipeline di inferenza: per ogni campione il modello riceve in ingresso l'immagine del documento e il prompt testuale, e produce un output in testo libero. La funzione `normalize_pred()` estrae la predizione finale cercando l'ultima occorrenza di ANSWERABLE o UNANSWERABLE nell'output, gestendo il caso in cui la prima parola sia contenuta nella seconda. Quando nessuna delle due etichette è presente nell'output si registra un parse fail e il campione viene classificato come ANSWERABLE per default poichè si considera che risponda puntualmente senza seguire le istruzioni binarie indicate.

Come riportato in figura 4 i modelli condividono un `SYSTEM_MESSAGE` fisso che vincola l'output a una sola parola (ANSWERABLE o UNANSWERABLE) e un `BASE_INSTRUCTION` che istruisce il modello a guardare il documento per decidere se la domanda è rispondibile.




Figure 3: Pipeline di inferenza per ogni campione:

SYSTEM_MESSAGE:

"You are a binary classifier. You must reply with ONLY one word: ANSWERABLE or UNANSWERABLE. Never extract text from the document. Never answer the question itself."

BASE_INSTRUCTION:

"You are a binary classifier. Look at the document and decide whether the question can be answered using ONLY the information visible in the document."

Figure 4: Prompt di sistema e istruzione base condivisi da tutti i modelli.

La funzione `run_inference` è unica per tutti i modelli: riceve la funzione di inferenza specifica del modello, il nome identificativo e la strategia, costruisce il prompt via `build_prompt`, e salva i risultati in un file JSON su Google Drive (`predictions_{model}_{strategy}.json`), permettendo sessioni separate per ciascun modello a causa dei vincoli di VRAM di Colab su cui sono state eseguite le inferenze.

Estensione multi-pagina. Per MP-DocVQA, la novità architetturale rispetto a SP-DocVQA è la funzione `get_window_pages`, che seleziona una finestra di W pagine centrata sulla pagina contenente la risposta (`answer_page_idx`). Con $W=1$ il modello riceve solo la pagina rilevante; con $W=2$ riceve anche una pagina di contesto adiacente.

Metriche e analisi dei risultati pre-mitigazione Single Page. Tutte le metriche F1 riportate in questo lavoro sono calcolate sulla classe positiva UNANSWERABLE, mai come media tra le due classi; la accompagniamo con la clean accuracy, calcolata sul sottoinsieme di domande non corrotte. Essendo il dataset bilanciato, l’accuracy globale coincide con la media tra recall e clean accuracy, e può quindi mascherare comportamenti opposti tra le due classi: per questo le riportiamo separatamente.

$$\text{Acc}_{cl} = \frac{TP + TN}{Totale} \xrightarrow{TP=FN=0} \frac{TN}{TN + FP} \quad (1)$$

I risultati baseline mostrati nella tabella 2 e in figura 5 rivelano tre lacune sistematiche. Gemma3-4B mostra un recall sulla classe *unanswerable* di 0.35 pur seguendo sempre il formato richiesto (0 parse fail): si tratta di un vero bias di calibrazione verso ANSWERABLE, poiché il modello classifica quasi ogni domanda come rispondibile senza verificarne il contenuto nel documento. Phi3.5-Vision mostra un recall ancora più basso (0.22), ma il dato è in larga parte un artefatto: con 159 parse fail su 198 campioni il modello estrae testo dal documento invece di produrre l’etichetta binaria, venendo penalizzato dal default ANSWERABLE più che da una scelta deliberata. Il crollo di F1 su corruzione di tipo *element* e *layout* indica che nessuno dei due modelli è in grado di ragionare sulla struttura spaziale del documento: solo Qwen2-VL-2B mantiene F1 elevato su tutte e tre le tipologie, pur con 119 parse fail propri. Tutti e tre i modelli mostrano ottimi valori di F1 sulla corruzione di tipo *entity*, poiché richiede principalmente il riconoscimento di nomi, date e numeri nel testo del documento, un’abilità vicina all’OCR in cui i modelli multimodali sono già ben addestrati.

Modello	Acc.	Prec.	Rec.	F1	Parse fail
Qwen2-VL-2B	0.65	0.71	0.49	0.58	119
Gemma3-4B	0.65	0.85	0.35	0.50	0
Phi3.5-Vision	0.56	0.69	0.22	0.34	159

Table 2: Metriche globali baseline Single-Page.




Figure 5: F1 (UNANSWERABLE) e clean accuracy per tipo di corruzione (calcolata sui campioni non corrotti, vedi eq. 1)

2.5 Parte 3: Strategie di Mitigazione

Alla luce delle lacune identificate, sono state definite tre strategie di in-context learning, applicate esclusivamente tramite modifica del prompt testuale, senza alcun fine-tuning del modello. Ciascuna strategia è motivata da un pattern specifico osservato nei risultati baseline discussi (Figura 5).

Few-shot. Per contrastare il recall basso sulla classe UNANSWERABLE: bias di calibrazione su Gemma (0.35) ed i parse fail elevati su Phi (0.22), vengono inseriti nel prompt due esempi annotati con ragionamento esplicito, uno per classe, per mostrare che UNANSWERABLE è una risposta legittima e rinforzare il formato di output richiesto.

Prompt few-shot :

Example 1:

Question: “What is the value shown in the bottom-left table?”

Reasoning: The document contains a table at the top-right, not bottom-left.

The referenced element does not exist in this position.

Answer: UNANSWERABLE

(Example 2 nel prompt mostra il caso speculare ANSWERABLE.)

Knowledge Injection. Il crollo di F1 su *element* e *layout* suggerisce che i modelli non sanno cosa cercare nel documento per rilevare una corruzione strutturale. La strategia inietta nel prompt la definizione esplicita delle tre tipologie di corruzione, guidando il modello in una verifica sistematica prima di rispondere.

Prompt knowledge :

Before answering, verify the following in the document image:

- Entities: check that any name, date, number, or organization mentioned in the question actually appears in the document.
- Elements: check that any referenced element (table, figure, chart, footnote) exists in the document.
- Layout: check that any referenced position

(top, bottom, left, right)
 matches the actual position of elements in
 the document.

Chain-of-Thought (CoT). Oltre a forzare una verifica più sistematica del documento (Sezione 3.1), il CoT viene adottato per ridurre i parse fail, frequenti al baseline su Phi e Qwen: il ragionamento esplicito in due passi prima della risposta finale richiede di aumentare `max_new_tokens` da 10 a 64, evitando che l’etichetta finale venga troncata.

Prompt CoT :
 Think step by step:
 1) What does the question ask for?
 2) Is it visible in the document image?
 YES → ANSWERABLE
 NO → UNANSWERABLE
 Your last line must be exactly: ANSWERABLE
 or UNANSWERABLE.

3 Risultati

3.1 SP-DocVQA Analisi risultati

I risultati baseline, già discussi nella Sezione 2.4, evidenziano come Gemma3-4B e Phi3.5-Vision soffrano di un forte bias verso ANSWERABLE (recall 0.35 e 0.22), mentre Qwen2-VL-2B risulta il modello più bilanciato ($F1=0.58$). Le strategie di mitigazione producono effetti asimmetrici (Figure 6, 7, 8).

Su **Gemma** nessuna strategia è efficace: come mostrano le frecce in Figura 7, tutte le mitigazioni spostano il punto verso l’alto a sinistra rispetto al baseline (recall più basso, precision più alta) anziché correggere il bias; il recall rimane sotto 0.35, CoT lo peggiora ulteriormente (0.20), e $F1=0.00$ su layout persiste con tutte le strategie (vedi figura 8) .

Su **Phi**, sia il few-shot sia la knowledge injection spostano il punto verso destra e verso l’alto (Figura 7), aumentando contemporaneamente precision e recall; il CoT, al contrario, riduce la recall nonostante l’aumento di precision. La knowledge injection produce il guadagno maggiore: $F1$ sale da 0.34 a 0.58, con miglioramenti su element (0.27→0.61) e una riduzione marcata dei parse fail (159→70, Tabella 3).

Strategia	Gemma	Phi	Qwen
Baseline	0	159	119
Few-shot	0	155	57
CoT	0	28	7
Knowledge	0	70	22

Table 3: Parse fail per modello e strategia nel task DocVQA Single Page.

Su **Qwen**, tutte le strategie aumentano il recall fino a valori prossimi a 1.0, ma la clean accuracy crolla da 0.80 a 0.15 con CoT e a 0.21 con knowledge injection (Figura 8): il modello sviluppa un bias opposto, classificando quasi tutto come UNANSWERABLE. Few-shot

rappresenta il miglior compromesso ($F1=0.70$, clean accuracy=0.43), l’unica strategia che migliora $F1$ senza il collasso sulla classe pulita osservato nelle altre due.




Figure 6: F1 (UNANSWERABLE) per vari modelli e strategie nel task DocVQA Single Page




Figure 7: Precision vs Recall: Effetto delle mitigazioni nel task DocVQA Single Page




Figure 8: Heat Map di F1 (UNANSWERABLE) e clean accuracy per tipo di corruzione, baseline vs mitigazioni nel task DocVQA Single Page

3.2 MP-DocVQA : Analisi risultati

Sotto $W=1$, i risultati multi-pagina confermano gli stessi pattern osservati su SP-DocVQA (bias di Gemma e Phi, crollo su *element* e *layout*, Few-shot come compromesso più stabile): la lacuna identificata non è quindi specifica del setting single-page. L’aspetto nuovo di questo setting è l’effetto della window size: $W=1$ risulta superiore o equivalente a $W=2$ per tutti i modelli tranne Gemma, che beneficia leggermente del contesto aggiuntivo (Figura 10), un effetto che la heatmap seguente permette di approfondire.

La heatmap di Figura 9 mostra una netta divergenza tra modelli. **Gemma** è l’unico a guadagnare $F1$ su *element* e *layout* con $W=2$ in tutte le strategie (es. baseline 0.17 → 0.31 su entrambi), a fronte di un lieve calo della clean accuracy (0.97 → 0.94): il contesto aggiuntivo lo spinge

verso UNANSWERABLE, mitigando il suo bias principale. Su **Qwen e Phi**, passando da $W=1$ a $W=2$ l'effetto è opposto: *element* e *layout* calano o restano saturi a zero, mentre la clean accuracy recupera (Qwen baseline 0.72 $\rightarrow$ 0.84; Phi baseline 0.91 $\rightarrow$ 0.92); entrambi si spostano verso ANSWERABLE, per Phi, un'amplificazione dello stesso bias già osservato in 3.1. Una possibile spiegazione è che $W=2$ raddoppi il numero di token visivi nel contesto, diluendo il budget di attenzione dedicato alla pagina rilevante: per Gemma, già conservativo, questo aumenta l'incertezza e abbassa la soglia per UNANSWERABLE; per Qwen e Phi, più inclini a un comportamento estrattivo (coerente con gli alti parse fail al baseline), il contenuto visivo aggiuntivo offre più occasioni di trovare per caso qualcosa che sembra confermare la domanda, favorendo ANSWERABLE.




Figure 9: F1 (UNANSWERABLE) per tipo di corruzione (entity, element, layout) e accuracy su campioni clean nel task DocVQA Multi Page




Figure 10: F1 (UNANSWERABLE) per strategia e window size sui tre modelli nel multi-page nel task DocVQA Multi Page

4 Conclusioni

Questo lavoro propone una pipeline per valutare la capacità dei Vision LLM di riconoscere domande unanswerable in Document VQA, con corruzione puramente visiva, non linguistica.

Nessuna strategia di mitigazione funziona in modo universale sul **single-page**: la knowledge injection aiuta solo Phi (parse fail e recall migliorano insieme); le stesse strategie spingono Qwen verso il bias opposto (clean accuracy sotto 0.21); Gemma resta insensibile a tutte, bloccato sul bias verso ANSWERABLE. Il few-shot è l'unica strategia robusta su tutti e tre, e su Qwen ottiene il miglior risultato dello studio ($F1=0.70$): pur essendo il più piccolo (2B), è il modello più efficace, la scala maggiore non è un vantaggio qui.

Infine, nel setting **multi-pagina**, $W=2$ non produce un beneficio sistematico ma un effetto specifico per modello: Gemma migliora verso UNANSWERABLE, mentre Qwen e Phi si spostano verso ANSWERABLE, segno che, a questa scala, il contesto multi-pagina non viene gestito in modo uniforme.

Sul fronte delle limitazioni, Phi e Qwen producono molti parse fail al baseline single-page (159 e 119 su 198), rivelando una tendenza estrattiva poco adatta a una classificazione binaria. Il Chain-of-Thought, inoltre, peggiora le prestazioni nella maggior parte dei modelli, segno che il ragionamento esplicito richiede una capacità parametrica che i modelli da 2-4B non raggiungono.

References

- [1] M. Mathew, D. Karatzas, and C. V. Jawahar, "DocVQA: A Dataset for VQA on Document Images," in *Proc. IEEE/CVF WACV*, pp. 2200–2209, 2021. arXiv:2007.00398. <https://www.docvqa.org/docvqa>
- [2] R. Tito, D. Karatzas, and E. Valveny, "Hierarchical Multimodal Transformers for Multi-Page DocVQA," *Pattern Recognition*, vol. 144, p. 109834, 2023. arXiv:2212.05935. <https://rrc.cvc.uab.es/?com=contestant>